Data Science Final Report
Crop Type Identification

R12922140 李恒寬、B10204007 趙華杉

資料前處理

Data Augmentation:

Data Augmentation 是一種在機器學習中常用的技術，目的在於增加訓練資料的多樣性，提升模型對於未見過的新數據的適應能力。

常見的 Data Augmentation 有對圖像做旋轉（Rotation）、翻轉（Flip）、縮放（Scaling）、平移（Translation）等等。ImageDataGenerator 是 Keras 中一個用於實現圖像資料擴增的工具，也是我們這次選擇使用的函式。

Data split:

訓練模型之前，將資料切分為訓練集（Training Set）、驗證集（Validation Set）和測試集（Test Set）是一個重要的步驟。這種切分有助於評估模型的性能並防止過度擬合。我們的分割占比為 Training 70% / Validation 20% / Testing 10%，

模型訓練

ResNet-18 是 Residual Networks（ResNet）系列的其中一個模型，它是由微軟研究院提出的深度神經網絡結構。ResNet-18 是相對較小的 ResNet 模型，適用於較簡單的圖像分類任務，同時具有較小的參數量，使得它在計算和記憶體需求上相對較輕。ResNet-18 模型結構簡圖如右:

ResNet-18 的主要特點和結構：

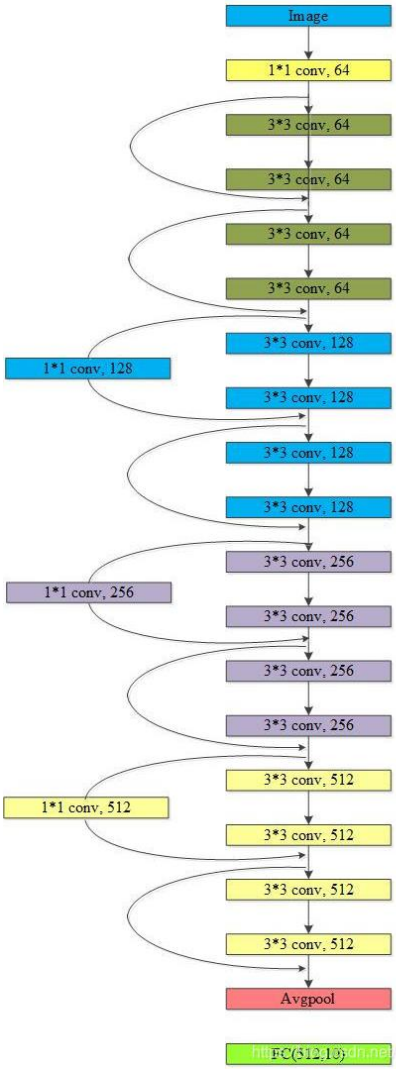

殘差塊(Residual block)結構： ResNet-18 包含基本的殘差塊結構，每個殘差塊由兩個卷積層組成。具體而言，每個殘差塊包括一個 3x3 的卷積層和一個具有瓶頸結構的殘差塊。

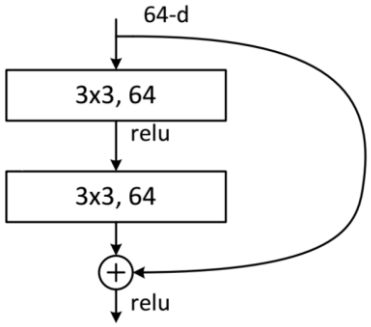

瓶頸結構(Bottleneck layer)： 在每個殘差塊中，卷積層使用了瓶頸結構，包括 1x1、3x3 和 1x1 的卷積核，以減少計算複雜性。

跳躍連接(Skip Connections)： 每個殘差塊引入了跳躍連接，將輸入的特徵與殘差部分相加，並透過恆等映射（identity mapping）來保留原始輸入的信息。

全局平均池化(Global Average Pooling)： 在網絡的最後，ResNet-18 使用全局平均池化將特徵圖的尺寸降維為 1x1，然後通過一個全連接層進行分類。

深度： ResNet-18 總共包含 18 層神經網絡層，包括卷積層、批次正規化（Batch Normalization）層和全連接層。

Hyperparameter 是指模型訓練過程中需要手動設置的配置，這些配置不能由模型自己學習得到，而需要人為指定。與模型的權重參數（parameters）不同，Hyperparameter 通常在模型訓練之前設置，並且它們的值通常通過實驗和調參的方式來選擇。

本次訓練模型時主要調整的 hyperparameter 如下:
學習速率（Learning Rate）： 控制模型參數更新的步長，過大的學習速率可能導致模型不收斂，而過小的學習速率則可能使模型訓練過程非常緩慢。

訓練迭代次數（Epochs）： 整個訓練數據集被模型遍歷的次數，訓練的迭代次數越多，模型可能越能適應訓練數據，但也可能導致過度擬合。
我們測試 20 / 30 / 50 / 100 發現超過 25 個 epoch 的時候 training 與 validation 的準確率趨近穩定，因此最後決定使用 30 個 epoch。

優化器（Optimizer）： 決定模型更新權重的具體算法，例如隨機梯度下降（SGD）、Adam、RMSprop 等。我們選擇的 optimizer 是 SGD (Stochastic Gradient Descent)，是一種優化算法，用於訓練機器學習模型。SGD 是梯度下降算法的變種，它在每次迭代(epoch)中僅使用一個樣本（或一小批樣本）的梯度來更新模型的參數，而不是使用整個數據集的梯度。

損失函數(Loss Function) :
Loss Function 是在機器學習和中使用的一個重要的衡量標準，用於評估模型預測與實際目標之間的差異。我們使用的損失函數是（CrossEntropyLoss），通常用於分類問題。處理多類分類問題時，CrossEntropyLoss 衡量了模型預測的概率分佈與實際標籤之間的差異。這個損失函數是為了最小化模型預測和實際標籤之間的交叉熵，從而提高模型的準確性。

結果討論

我們主要的模型事先 split data 再進行 data augmentation，且 data augmentation 僅對圖像做單純的水平翻轉產生。

訓練結果

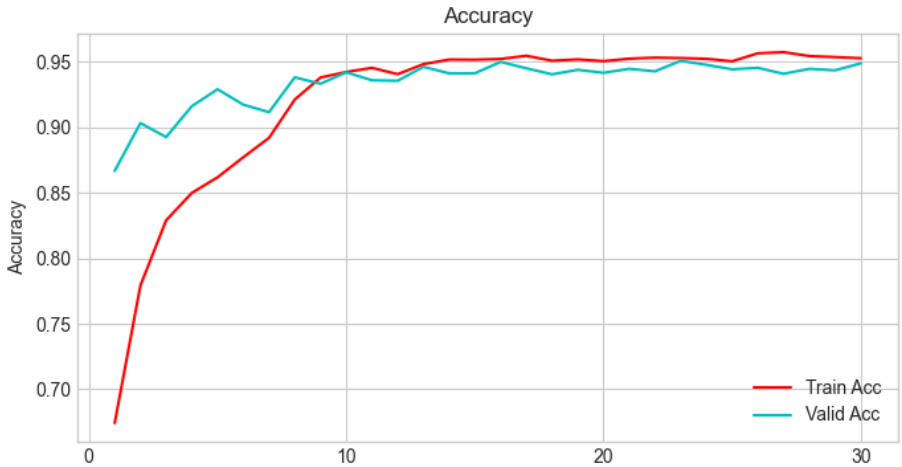

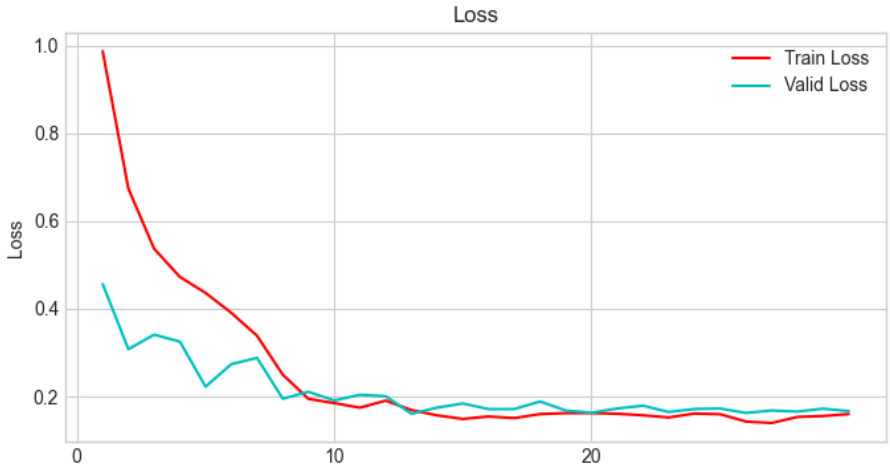

testing accuracy 為 95.22%

testing loss 為 0.155

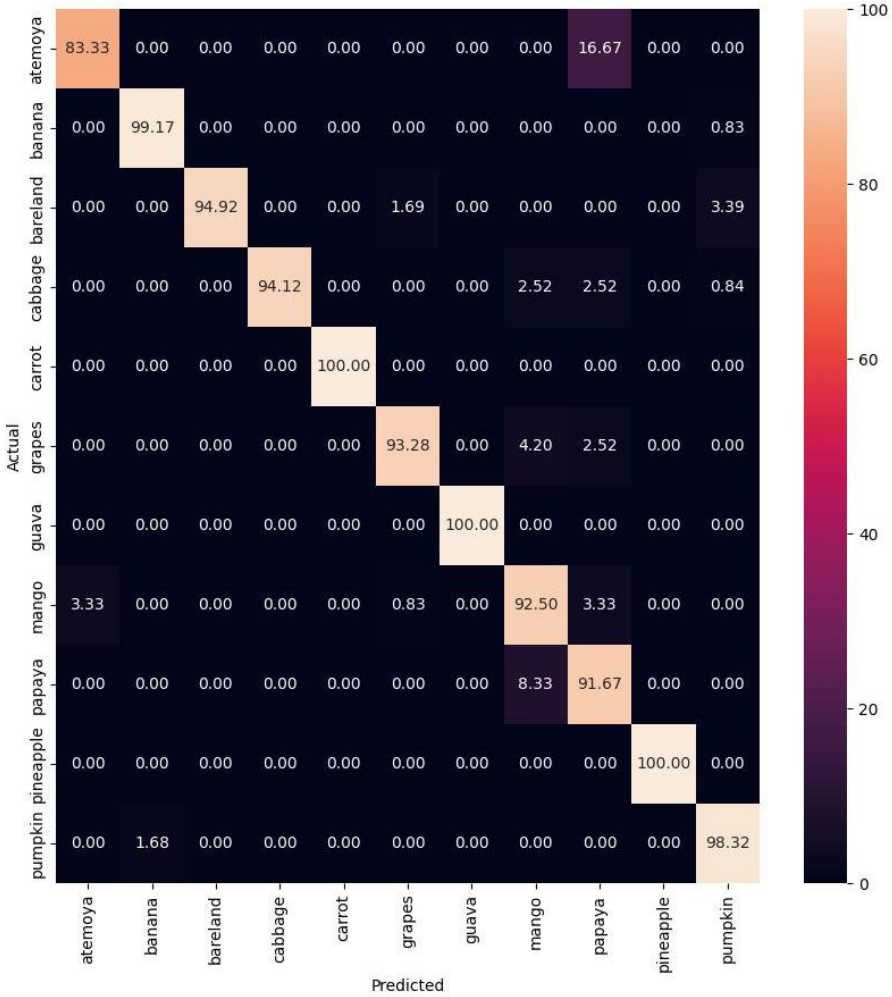

由 confusion matrix 可以看到模型在辨識 carrot、guava、pineapple 特別好，我們認為是因為這三種圖片含有有別於其他種圖片的特徵讓模型能夠輕易辨認，模型在 atemoya、papaya、mango 的辨識上表現較差，我們認為原因可能是他們有類似的特徵讓模型在辨識時產生混淆

由於 resnet18 屬於 ImageNet 類型的模型，所以一開始 validation accuracy 高於 training accuracy 屬於正常，但是可以由折線圖看到大概 10 個 epoch 後，training accuracy 就不再低於 validation accuracy。

實驗探討

影響模型訓練結果的變因主要有二，分別為 data augment 的方式不同以及 split data 與 data augmentation 進行的順序。

我們嘗試了兩種 augment 的方式，一是僅對圖像做單純的水平翻轉，另種是在給定的變異條件包含 45 度範圍內旋轉、平移、縮放、剪切影射(shear)、水平翻轉，來隨機生成 5 張。

除了我們主要的模型外，還有另外三種組合

1. 兩張 augment、先 data augmentation 後 split data

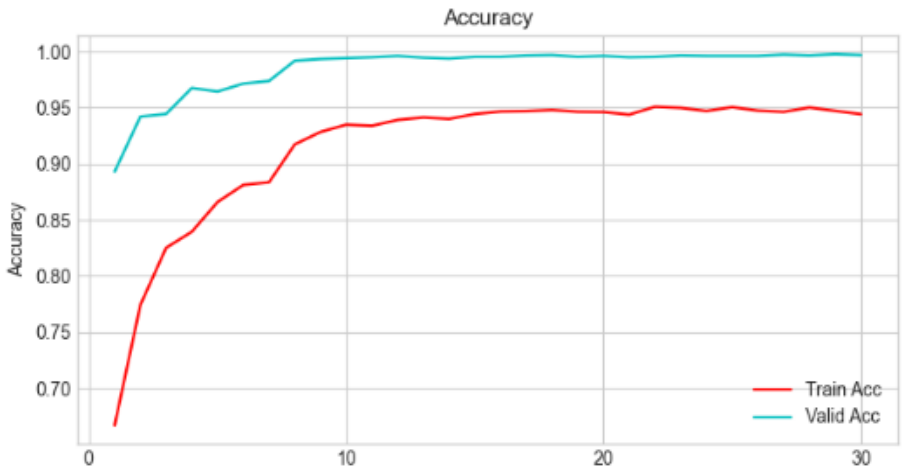

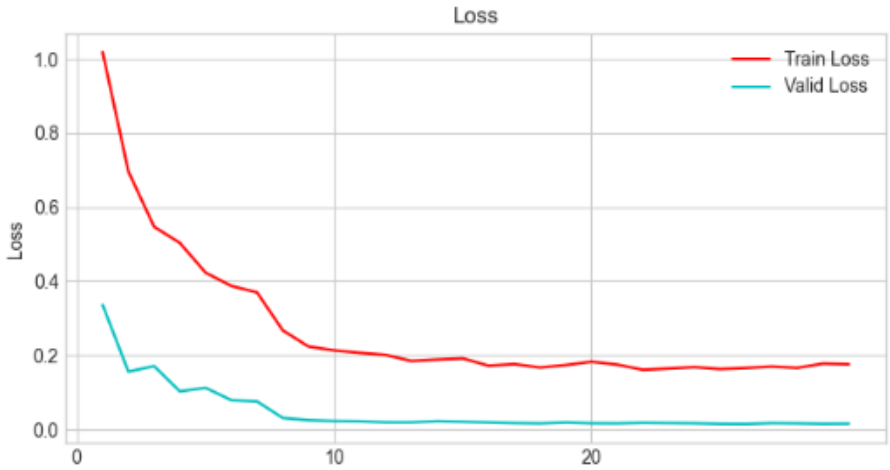

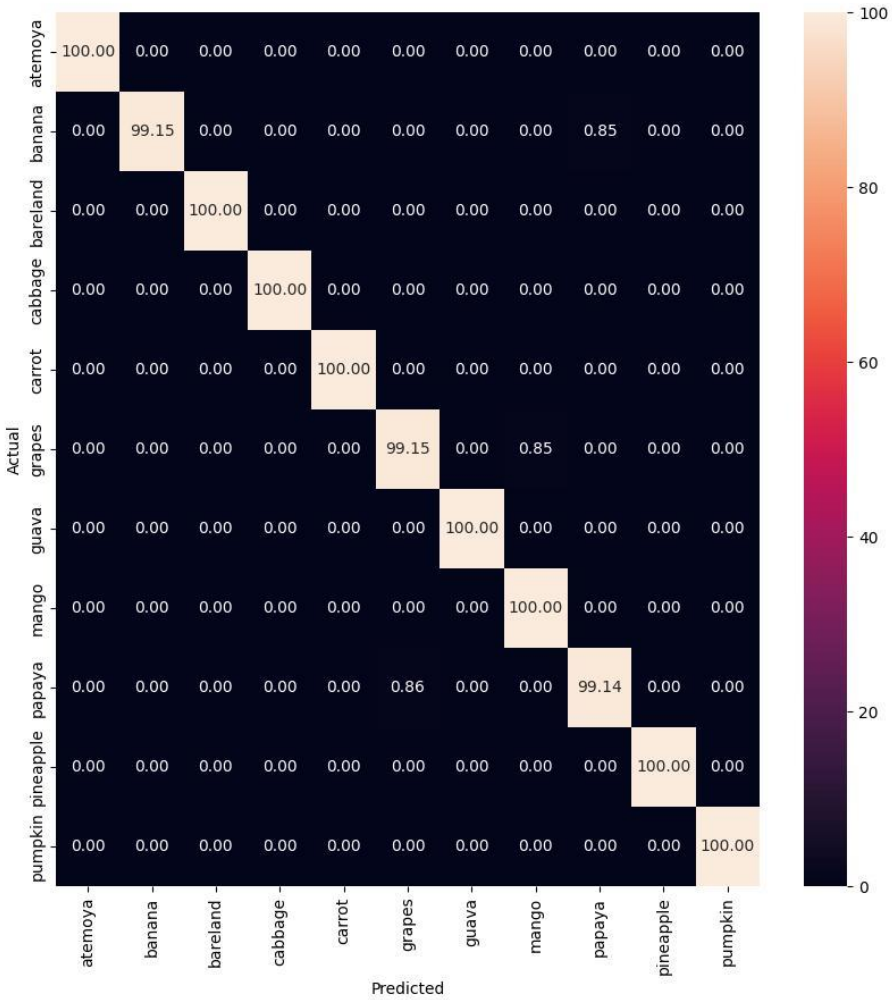

2. 五張 augment、先 split data 後 data augmentation

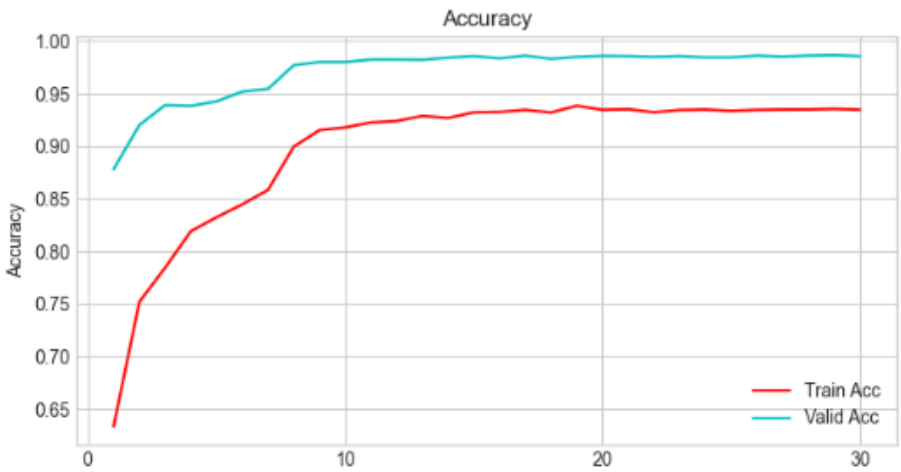

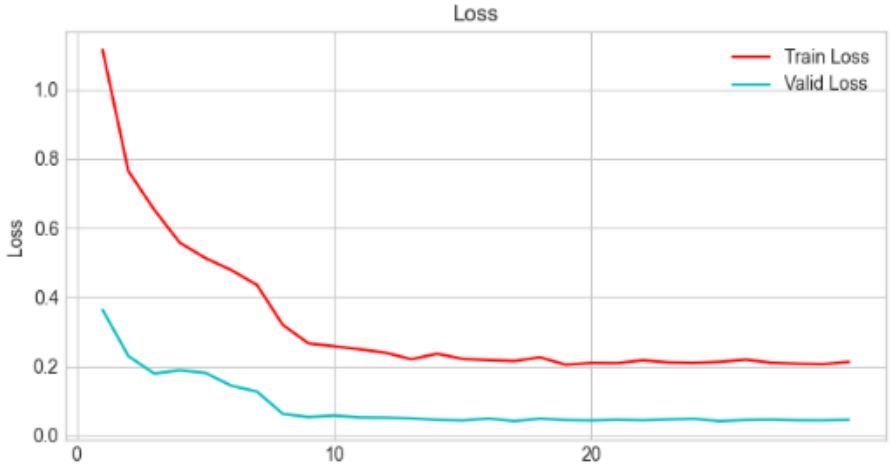
Loss
Train Loss
Valid Loss
Loss
1.0
0.8
0.6
0.4
0.2
0.0
0
10
20

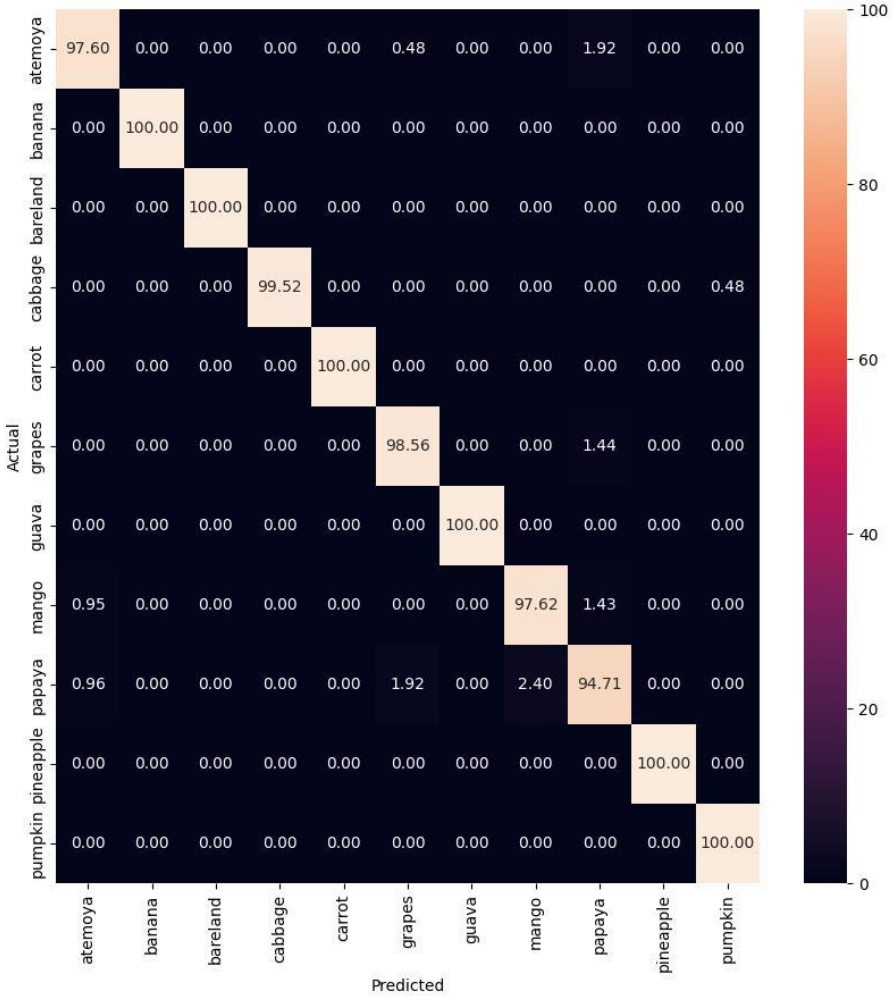
Actual
Predicted
atemoya 97.60 0.00 0.00 0.00 0.00 0.48 0.00 0.00 1.92 0.00 0.00
banana 0.00 100.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00
bareland 0.00 0.00 100.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00
cabbage 0.00 0.00 0.00 99.52 0.00 0.00 0.00 0.00 0.00 0.00 0.48
carrot 0.00 0.00 0.00 0.00 100.00 0.00 0.00 0.00 0.00 0.00 0.00
grapes 0.00 0.00 0.00 0.00 0.00 98.56 0.00 0.00 1.44 0.00 0.00
guava 0.00 0.00 0.00 0.00 0.00 0.00 100.00 0.00 0.00 0.00 0.00
mango 0.95 0.00 0.00 0.00 0.00 0.00 0.00 97.62 1.43 0.00 0.00
papaya 0.96 0.00 0.00 0.00 0.00 1.92 0.00 2.40 94.71 0.00 0.00
pineapple 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 100.00 0.00
pumpkin 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 100.00
atemoya banana bareland cabbage carrot grapes guava mango papaya pineapple pumpkin
100
80
60
40
20
0

3. 五張 augment、先 data augmentation 後 split data

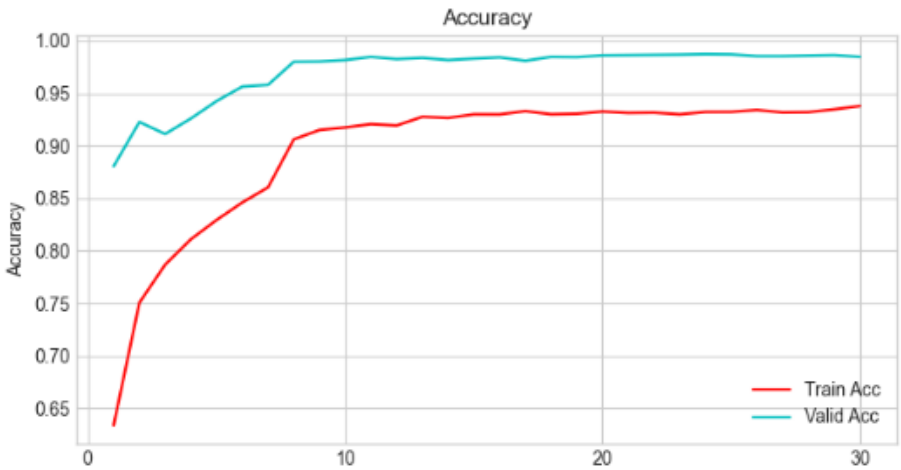

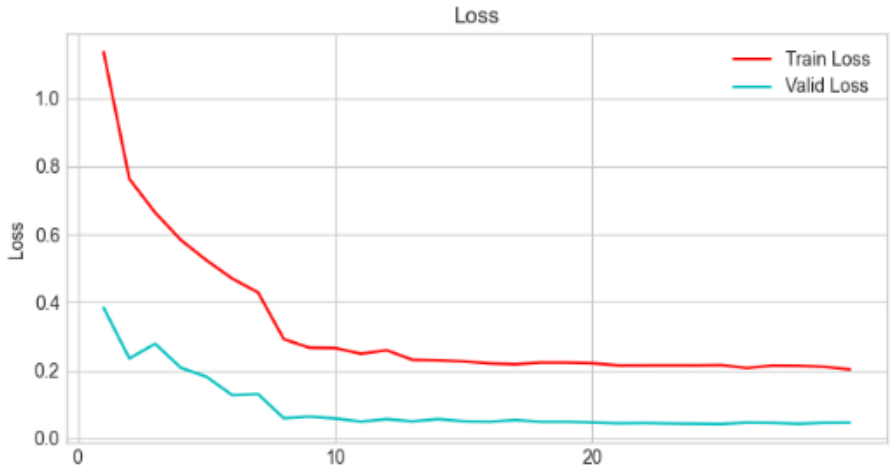

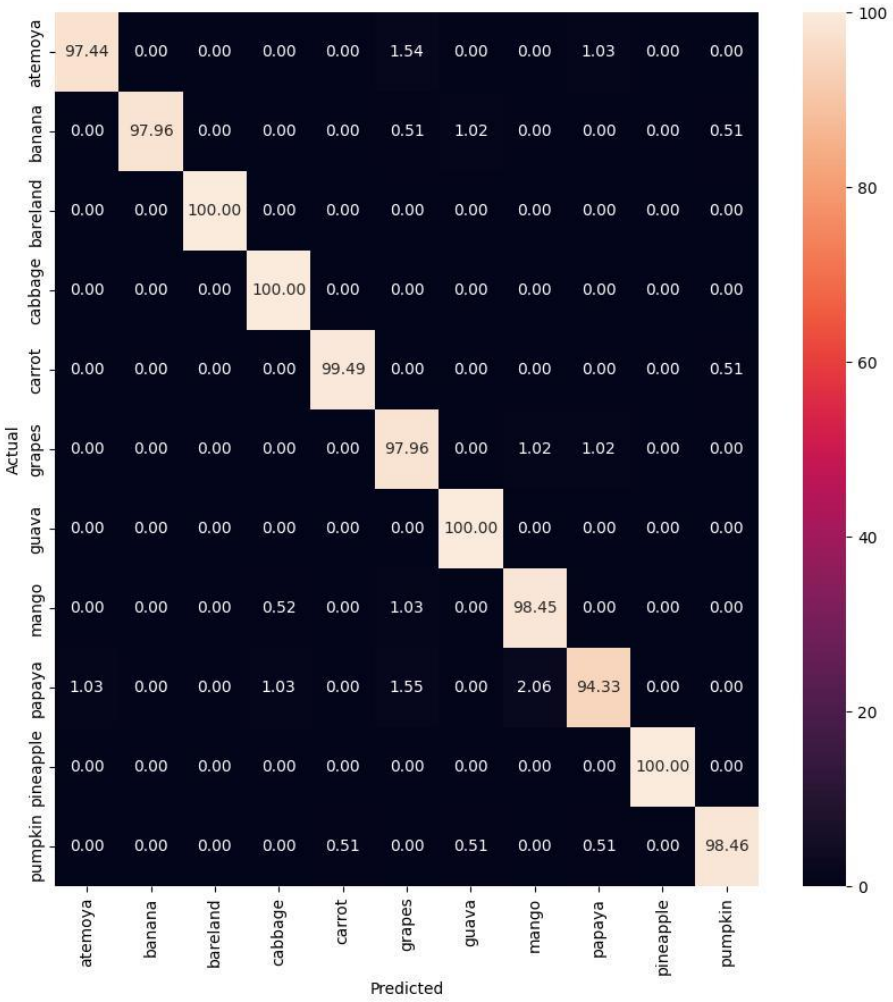

結論

除了第一個模型以外，其他三個模型都會有發生 training accuracy 低於 validation 及 testing accuracy 的情況，這種情況不常見，並非是發生 overfitting 或 underfitting 的狀況，我們猜測可能是因為先做 augmentation 再 split 導致一張圖片的原始 data 及其 augment data 分別被 split 到不同資料夾而產生 data leakage，也就是模型在 training 時獲得其中一張的 label，然後在 testing 或 validation 時可以依照該 label 輕易猜出另一張的 label。另外產生五張 augment data 且先 split 的組合可能因為使用 resnet18 這種模型架構太過簡單，才會 training accuracy 低於 validation 及 testing accuracy 的情況。